

数据结构实验报告

姚苏航 PB22061220

1 问题描述

1.1 实验题目

利用哈希表统计两源程序的相似性。

1.2 基本要求

对于两个 C 语言的源程序清单，用哈希表的方法分别统计两程序中使用 C 语言关键字的情况，并最终按定量的计算结果，得出两份源程序的相似性。

1.3 测试数据

事先给出的 file 文件夹，包含关键词表和三份源程序文件，程序之间有相近的和差别大的。文件内容详见附录 B。

2 需求分析

1. 扫描给定的源程序，累计在每个源程序中 C 语言关键字出现的频度 (为保证查找效率，建议自建哈希表的平均查找长度不大于 2)，通过这种方式扫描两个源程序，提取其特征向量。
2. 通过计算向量 X_i 和 X_j 的相似值来判断对应两个程序的相似性，相似值的判别函数计算公式为：

$$S(X_i, X_j) = \frac{X_i^T \cdot X_j}{|X_i| \cdot |X_j|} \quad (1)$$

通过这种方式，可以初步判断两个源程序的相似性，如图 1 所示。其中 S 反映了两向量的夹角的余弦，当 S 趋近于 1 时，两向量夹角趋于 0，即两向量趋于相似，反之亦然。




图 1: Similarity

3. 在有些情况下, S 不能很好地反映两向量的相似性, 还需要进一步的考虑。例如, 在 S 接近于 1 时, 两向量的模的差距不能很好地被反映, 如图 2 所示。因此引入几何距离 D , 用于反应两向量终点间的距离。




图 2: Distance

4. 通过分别比较很相近和差别很大的三个源代码, 实践这种方法的有效性。

3 概要设计

3.1 数据结构——哈希表

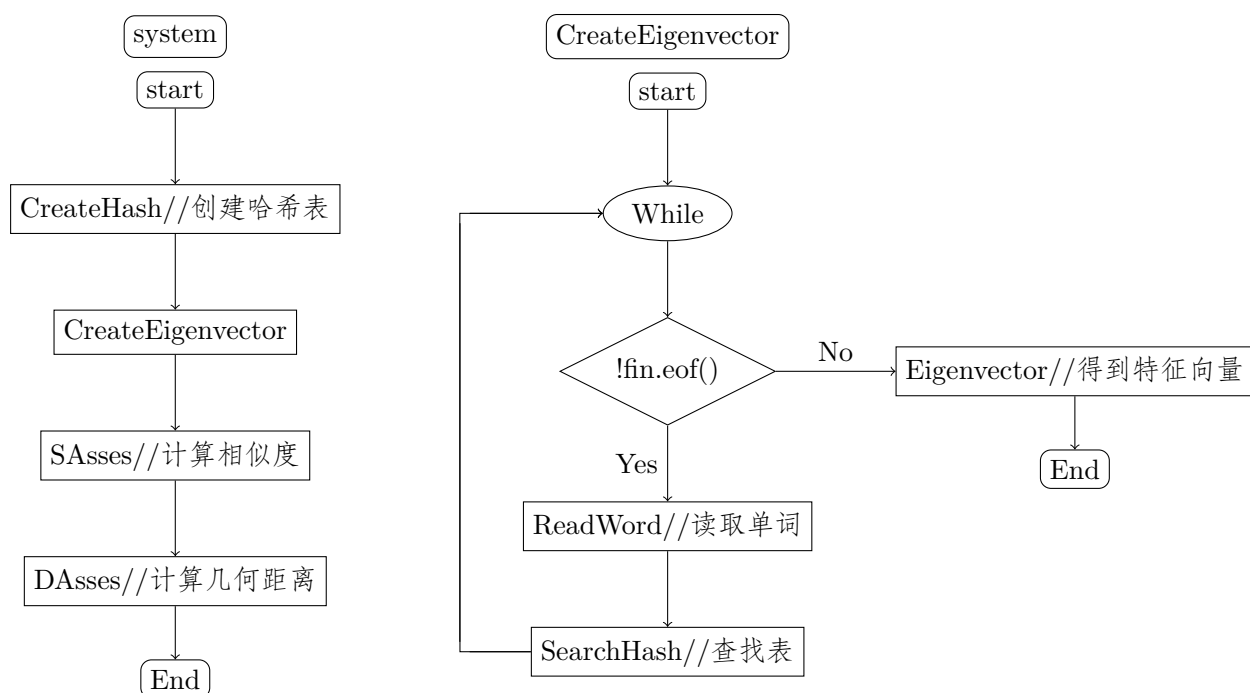
哈希表 (Hash table, 也叫哈希映射), 是根据键 (key) 直接访问在内存存储位置的数据结构。也就是说, 它通过计算一个关于键值的函数, 将所需查询的数据映射到表中一个位置来访问记录, 这加快了查找速度。这个映射函数称做散列函数, 存放记录的数组称做散列表。

由于散列 (hashing) 是一种用于以常数平均时间执行插入、删除、查找的技术。那些需要元素间任何排序信息的操作将不会得到有效支持。因此诸如 FindMin、FindMax 等操作都是哈希表不支持的。

在本实验中, 哈希表采用开散列的方法实现。处理冲突时把散列到同一槽中的所有元素都放在一个链表中。在查找时, 先计算元素的哈希值, 然后遍历该链表查找元素。通过拉链法 (即链地址法) 解决冲突有以下优点:

- (1) 拉链法处理冲突简单, 且无堆积现象, 即非同义词决不会发生冲突, 因此平均查找长度较短;
- (2) 由于拉链法中各链表上的结点空间是动态申请的, 故它更适合于造表前无法确定表长的情况;
- (3) 当结点较大时, 拉链法中增加的指针域可忽略不计, 因此节省空间;
- (4) 在用拉链法构造的散列表中, 删除结点的操作易于实现。只要简单地删去链表上相应的结点即可。

3.2 主程序流程及其模块调用关系



4 详细设计

4.1 实现概要设计中的数据结构 ADT

```
1  typedef struct {
2      KeyType key;
3      Datatype Data; // 记录关键字出现的次数
4  } ElemType;        // 包含关键字和数据
5
6  typedef struct LNode { // 哈希表结点
7      ElemType data;      // 查找表单元
8      LNode *next;        // 后继
9  } *LHptr;
10
11 typedef struct {
12     LHptr *elem;
13     int count; // 记录数
14     int size;  // 容量
15 } LHashTable; // 链地址存储法
```

4.2 实现每个操作的伪码，重点语句加注释

4.2.1 哈希表的创建与查找

Algorithm 1 创建哈希表

```
1: function CREATEHASH(LHashTable &H)
2:   ifstream fin("../file/keywords.txt", ios :: in);
3:   keyword[0]  $\leftarrow$  new char[30];
4:   for each i in [1, 22] do
5:     keyword[i]  $\leftarrow$  new char[10];  $\triangleright$  为每个节点分配空间
6:   end for
7:   fin.get(keyword[0], 26);  $\triangleright$  将无用内容读入 keyword[0], 关键字从 1 开始存储
8:   i  $\leftarrow$  1, j  $\leftarrow$  0;
9:   while !fin.eof() do
10:    fin.get(ch);
11:    if ch  $\geq$  97 & ch  $\leq$  122 then  $\triangleright$  判断是否为需要读取的关键词
12:      keyword[i][j]  $\leftarrow$  ch;  $\triangleright$  读取关键词
13:      j ++;
14:    else
15:      keyword[i][j]  $\leftarrow$  '\0';
16:      j  $\leftarrow$  0, i ++;  $\triangleright$  为读取下一个关键词做准备
17:    end if
18:  end while
19:  H.size  $\leftarrow$  43; H.count  $\leftarrow$  0
20:  H.elem  $\leftarrow$  new LHptr[H.size]  $\triangleright$  初始化为所有结点指针的头指针
21:  for each i in [0, H.size - 1] do
22:    H.elem[i]  $\leftarrow$  new LHNode;  $\triangleright$  为单个结点分配空间
23:    H.elem[i]->next  $\leftarrow$  nullptr;
24:  end for
25:  for each i in [1, 17] do
26:    n  $\leftarrow$  Hash(keyword[i]);
27:    p  $\leftarrow$  new LHNode; p->data.key  $\leftarrow$  new char[10];  $\triangleright$  分配空间
28:    p->next  $\leftarrow$  nullptr; p->data.Data  $\leftarrow$  0;  $\triangleright$  计数
29:    p->data.key  $\leftarrow$  keyword[i]  $\triangleright$  记录 key 值
30:    if !H.elem[n]->next then
31:      H.elem[n]->next  $\leftarrow$  p;
32:    else
33:      p->next  $\leftarrow$  H.elem[n]->next;
34:      H.elem[n]->next  $\leftarrow$  p;
35:    end if
36:  end for
37:  fin.close();
38: end function
```

Algorithm 2 查找哈希表

```
1: function SEARCHHASH(LHashTable H, int n, KeyType key)
2:    $p \leftarrow H.elem[n] \rightarrow next;$ 
3:   while  $p$  do
4:     if !strcmp(key,  $p \rightarrow data.key$ ) then                                ▷ 等于则返回 0
5:        $p \rightarrow data.Data++;$ 
6:       break;
7:     end if
8:      $p \leftarrow p \rightarrow next;$ 
9:   end while
10: end function
```

4.2.2 向量的生成与运算

Algorithm 3 读取文件生成向量

```
1: function CREATEEIGENVECTOR(LHashTable H, int X[], const string& FileAddress)
2:   InitHash();                                                            ▷ 初始化哈希表
3:   while !fin.eof() do
4:     ReadWord();                                                         ▷ 读取单词;
5:      $n \leftarrow Hash();$                                                  ▷ 计算哈希值;
6:     SearchHash();                                                       ▷ 搜索哈希表;
7:   end while
8:   for each  $i$  in  $[0, 43]$  do
9:      $p \leftarrow H.elem[i] \rightarrow next;$ 
10:    while  $p$  do
11:       $X[j++] \leftarrow p \rightarrow data.Data;$                         ▷ 用哈希表的记录生成特征向量
12:       $p \leftarrow p \rightarrow next;$ 
13:    end while
14:  end for
15:  fin.close();
16: end function
```

Algorithm 4 计算几何距离

```
1: function DASSES(const int X1[], const int X2[])
2:    $k, i, m \leftarrow 0;$ 
3:   for each  $i$  in  $[0, 16)$  do
4:      $m += (X1[i] - X2[i]) * (X1[i] - X2[i]);$                                 ▷ 计算 X1 和 X2 的差
5:   end for
6:    $k = sqrt(m);$                                                          ▷ 计算几何距离 D return  $k;$ 
7: end function
```

Algorithm 5 计算相似度

```
1: function SASSES(const int X1[], const int X2[])
2:    $n1, n2, i, m \leftarrow 0$ ;
3:   for each  $i$  in  $[0, 16)$  do
4:      $m+ = X1[i] * X2[i]$ ; ▷ 计算 X1 和 X2 的点积
5:      $n1+ = X1[i] * X1[i]$ ;
6:      $n2+ = X2[i] * X2[i]$ ;
7:   end for
8:    $n1 = \text{sqrt}(n1)$ ; ▷ 计算 X1 的模
9:    $n2 = \text{sqrt}(n2)$ ; ▷ 计算 X2 的模
10: return  $m / (n1 * n2)$ ; ▷ 返回相似度 S
11: end function
```

4.3 主程序和其他模块的伪码

Algorithm 6 判断相似性

```
1: function SYSTEM(void)
2:   CreateHash(H); ▷ 根据给定关键词创建哈希表
3:   CreateEigenvector(H, SimVec, "../file/similar.c"); ▷ 读取程序生成特征向量
4:   CreateEigenvector(H, DifVec, "../file/different.c");
5:   CreateEigenvector(H, MainVec, "../file/main.c");
6:    $\text{Similarity} \leftarrow \text{SAsses}(\text{SimVec}, \text{MainVec})$ ; ▷ 计算相似度 S 和几何距离 D
7:    $\text{Distance} \leftarrow \text{DAsses}(\text{SimVec}, \text{MainVec})$ ;
8:    $\text{Similarity} \leftarrow \text{SAsses}(\text{DifVec}, \text{MainVec})$ ;
9:    $\text{Distance} \leftarrow \text{DAsses}(\text{DifVec}, \text{MainVec})$ ;
10: end function
```

5 调试分析

5.1 问题分析与体会

本项目工程主要分为两个部分。第一部分是哈希表的创建和查找，第二部分是根据查找结果得到向量以及对向量的数学计算等处理。

在这两部分中，文件的读取和写入是必不可少的，因此，对文件的读写操作是调试的重点。在本实验中，根据给定的文件，选用适当的函数读取文件，并且注意想要获取的内容间分隔符的处理，是第一个难点，也是调试的重点。此外，文件读取状态的判断也是一个重点。

在正确地读取文件内容后，如何处理向量也是实验重点。在一开始，只是简单地将每个读取的向量的处理步骤转换成代码，造成了代码臃肿，复用性差，并且难以调试的问题。通过对代码的重构和优化，将向量的处理步骤封装成通用的函数，使得代码的复用性大大提高，并且易于调试，在实验过程中数学运算的错误也更易发现。

在本次实验中，注释发挥了重要的作用。通过对一些细节操作的注释，大幅加快了调试的速度。在遇到问题时能够很快找到解决方案。注释也大幅提高了代码可读性，在优化代码时，注释作为参考，指明了数据初始化的状态，重要操作的目的，方便了后期的维护与修改。

通过这次实验，我锻炼了自己处理多个文件的能力，认识了注释等好的编程习惯的重要性，提升了自己对非单一文件的项目工程的函数编写封装思路的理解。它不仅加深了我对哈希表的认识，了解了哈希表在查重方面的应用，还提高了自己代码的编写能力，能够更好更快地写出容易理解且便于调试的代码。

5.2 时空复杂度分析

5.2.1 时间复杂度

在初始化部分，由于哈希表通过散列函数查找元素的性质，哈希表的创建和查找操作的时间复杂度均为 $O(1)$ 。在特征向量的运算部分，由于每次运算需要遍历向量的每个元素，时间复杂度为 $O(n)$ 。

5.2.2 空间复杂度

在本实验中，哈希表的空间复杂度为 $O(n)$

5.2.3 平均查找长度

由计算得，成功时平均查找长度：

$$ASL = \frac{1 \times 13 + 2 \times 2 + 3 \times 1 + 4 \times 1}{17} \approx 1.4 < 2 \quad (2)$$

而失败时，平均查找长度：

$$ASL = \frac{1 \times 11 + 4 \times 1 + 2 \times 1}{43} \approx 0.40 < 2 \quad (3)$$

符合平均查找长度小于 2 的要求。

6 使用说明

用户将事先准备好的关键词表 (keyword.txt) 和需要统计相似性的程序放入 file 文件夹中，运行时程序将通过关键词表建立哈希表，并通过查找哈希表构建两程序的向量，最后通过判别函数计算两程序相似性和向量的几何距离。

在本项目中，使用事先给出的测试数据，准备三个编译和运行都无误的 C 程序，程序之间有相近的和差别大的，通过 similar.c 和 different.c 两个程序与 main.c 进行比较，可以直观展现出比较的效果。

7 测试结果

7.1 输入数据

输入数据从给出的测试文件中读取，读取 keyword.txt 文件生成哈希表，再分别读取 main.c, 相似的程序 similar.c, 差异较大的程序 different.c 并进行比较。

7.2 输出数据

输出结果显示在终端，内容如下：

X_(../file/similar.c):

0 1 1 4 0 1 0 3 3 1 2 1 2 0 1 1 4

X_(../file/different.c):

0 1 0 1 0 0 1 2 1 0 3 0 0 0 1 3 2

X_(../file/main.c):

0 1 1 3 0 1 0 3 2 1 2 1 2 0 1 1 4

S_(Sim&Main):0.988174

D_(Sim&Main):1.41421

S_(Dif&Main):0.740121

D_(Dif&Main):4.89898

A 实验源代码文件

为方便查看，附录中的链接文件均为 txt 格式

[define.h](#)

[main.cpp](#)

[OpenHashing.h](#)

[OpenHashing.cpp](#)

[system.h](#)

[system.cpp](#)

[SimAsses.h](#)

[SimAsses.cpp](#)

B 实验用测试文件

[main.c](#)

[different.c](#)

[similar.c](#)

[keyword.txt](#)